REDES NEURAIS ARTIFICIAIS (RNA)

RNA E CÁLCULO

INTELIGÊNCIA ARTIFICIAL

MAURICIO EVANDRO ELOY
ROGÉRIO AP. BATISTA DA SILVA

SUMÁRIO

1. **Dados, Informação e Conhecimento**
2. **Máquinas de Turing e Autômatos**
3. **Redes Neurais Biológicas**
4. **Redes Neurais Artificiais**
5. **Machine Learning e Deep Learning**

O QUE CONSEGUEM EXTRAIR DESTA IMAGEM?

https://www.menti.com/

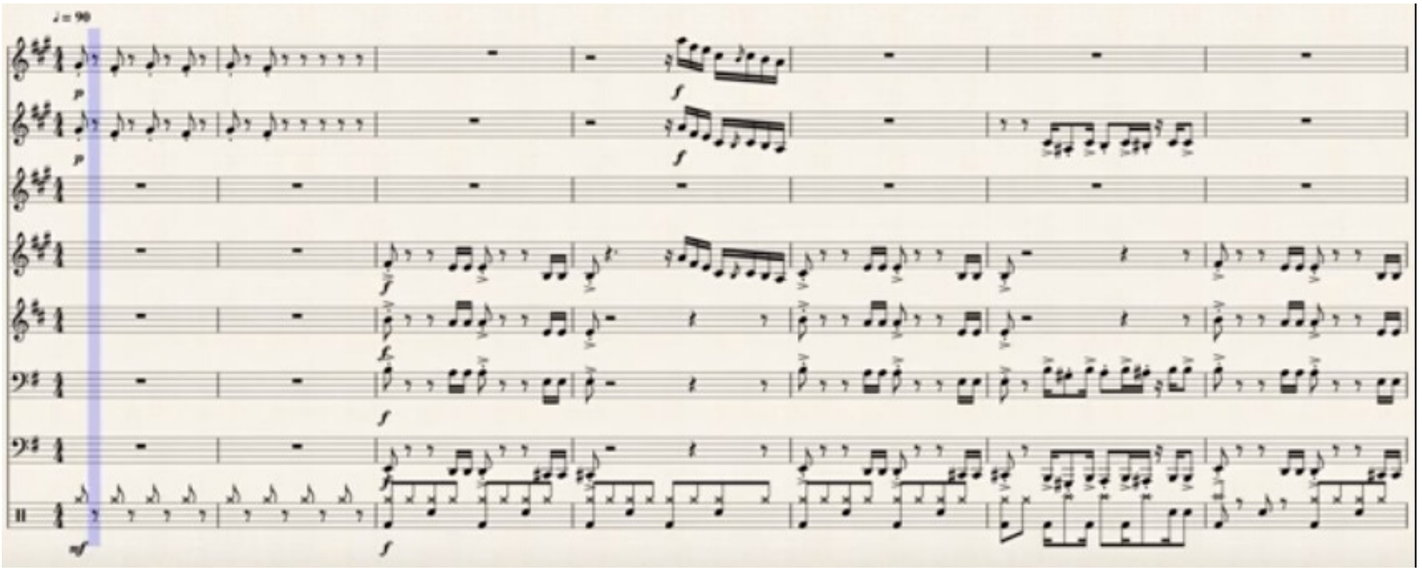

ALAN TURING

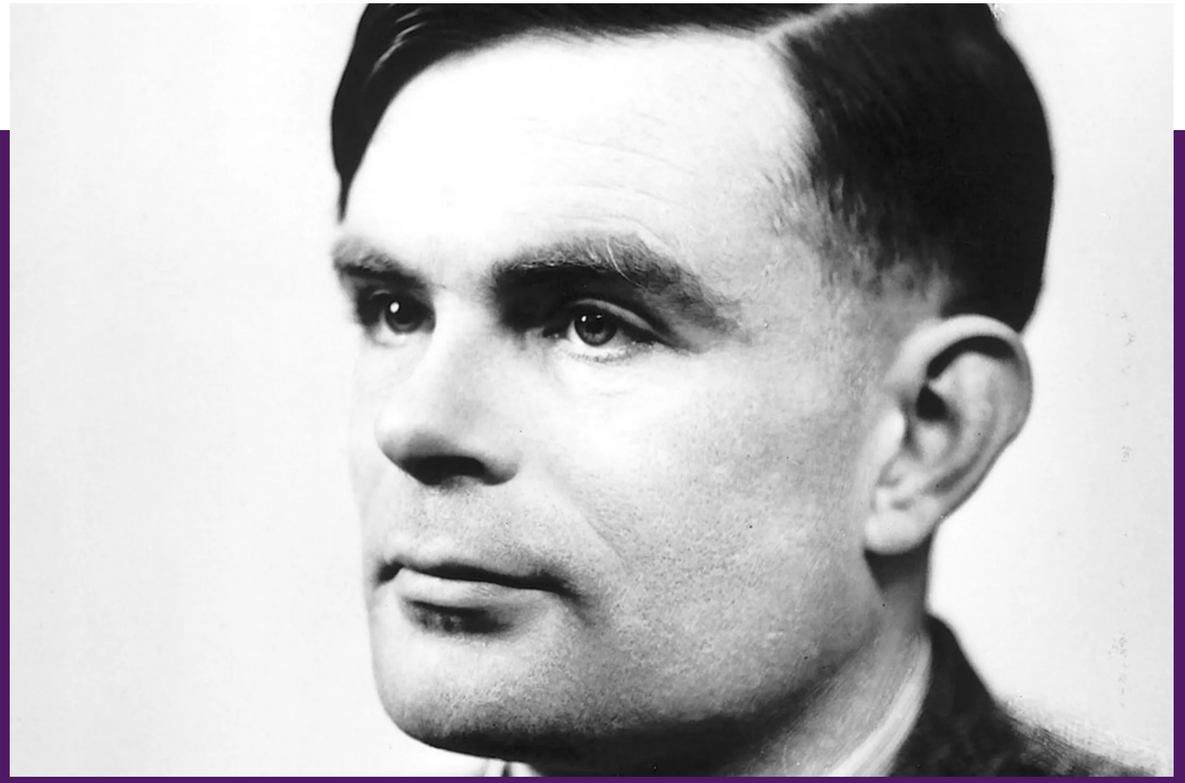

Alan Turing (1912-1954) foi um matemático britânico, pioneiro na computação considerado pai da Ciência da Computação e inteligência artificial.

MAQUINA DE TURING

HTTPS://IMAGES.APP.GOO.GL/IRNQUTINZRSUQ8KF7

A “Maquina de Turing” um protótipo dos computadores modernos. Turing trabalhou como funcionário do Governmente and Cypher School entre 1940 e 1941, e desenvolveu uma máquina capaz de decifrar o “Enigma”, código utilizado pelos nazistas, na Segunda Guerra Mundial entregando aos aliados a vitória mais rápida sobre os nazistas.

O COMPUTADOR

HTTPS://IMAGES.APP.GOO.GL/NCRUAWSVGVKVONAG8

E possível que o desenvolvimento do computador venha provar uma das maiores realizações tecnológicas. O computador pode vir ainda a se situar ao lado do uso do fogo a descoberta da roda e o aproveitamento da eletricidade[14].

ÁBACO

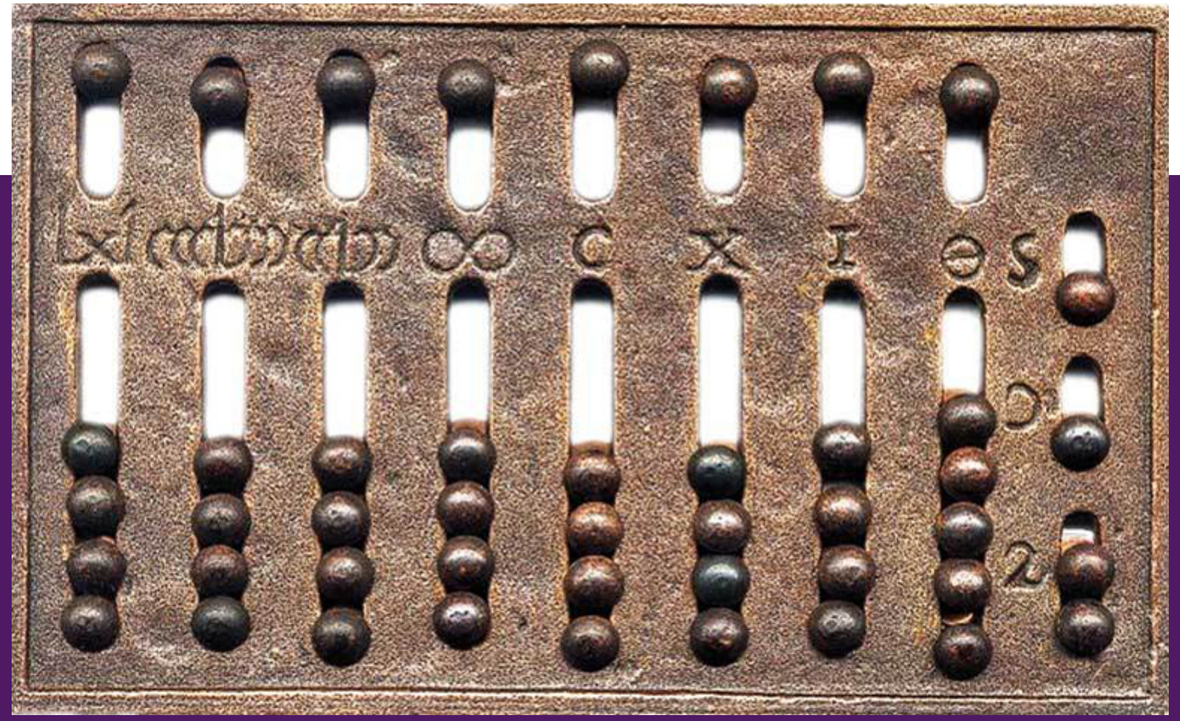

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

Podemos dizer que o primeiro computador foi o ábaco esse método de cálculo foi descoberto antes da roda, há indicações arqueológicas que o ábaco já era usado a 4000 a.C. A palavra ábaco deriva do babilônio, que significa pó, segundo uma versão, todos os cálculos eram feitos originalmente no pó, assim o pó se tornou o nome de qualquer forma de cálculo ou alternativamente o método de cálculo usado pelo ábaco teria sido primeiramente desenhado em linhas e rabiscos no pó.

O TESTE DE TURING E O PENSAMENTO

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

Allan Turing, questionou se poderia as máquinas pensarem isso foi proposto em sua questão primordial: com a questão posta, faltava apenas uma definição dos termos envolvidos. O que é uma “máquina”? E o que e “pensamento”?

JOGO DA IMITAÇÃO

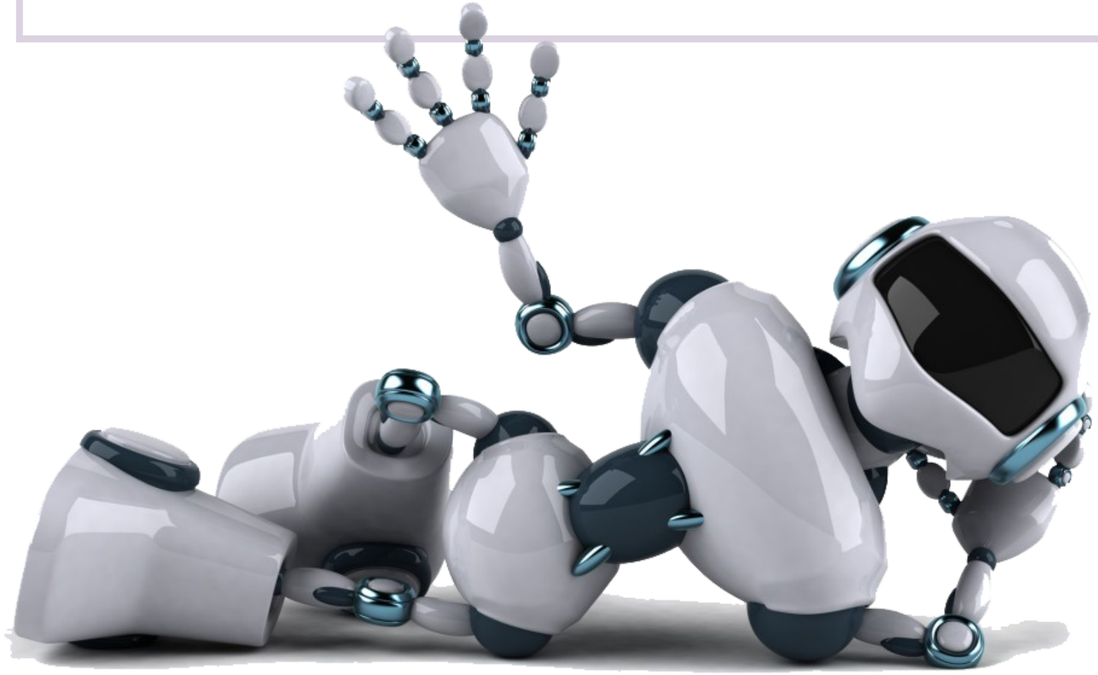

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

A versão “humana” do jogo possibilitaria um participante descobrir com suas perguntas a outros dois participantes sem velos e sem acesso direto a suas respontas sendo essas apresentadas por meio de um mediador descobrir quem era a mulher e quem era o homem[5].

INTELIGENCIA ARTIFICIAL FORTE X FRACA – SALA CHINESA

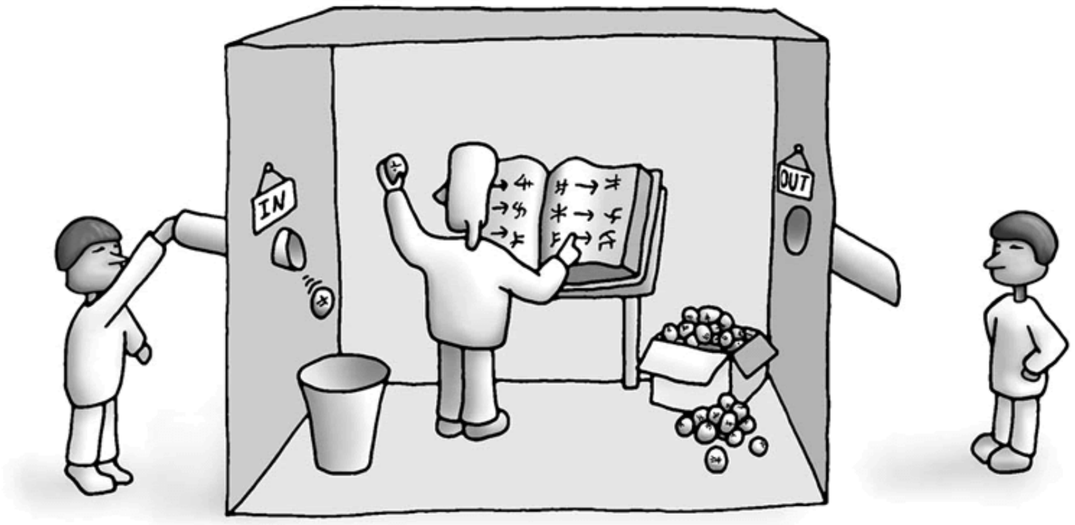

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

Pesquisadores da área de Inteligência Artificial (IA) dita “forte”, que usam como parâmetro filosófico o teste de "Turing", acreditam que um dia haverá programas de computadores tão sofisticados e complexos que serão capazes de reproduzir qualquer meio de ação desempenhada por um cérebro humano.

FILÓSOFO JOHN SEARLE

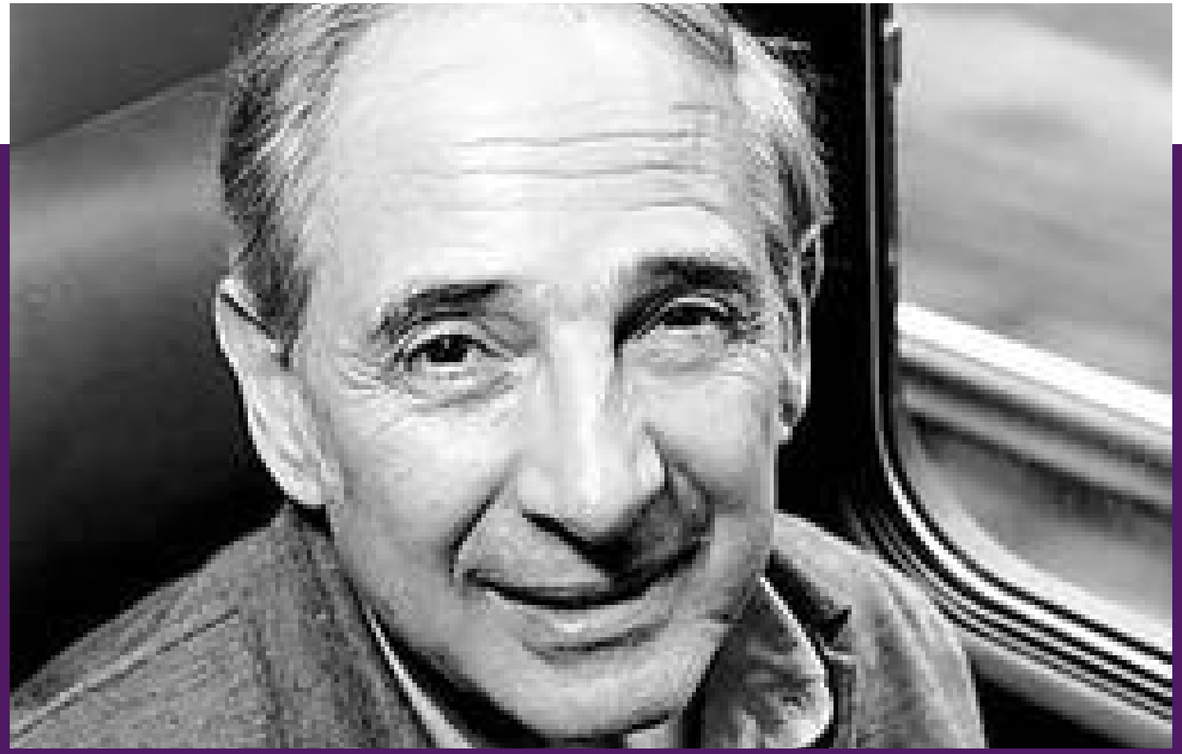

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

O filósofo John Searle, da Universidade de Berkeley, afirma que nenhum programa de computador, por mais sofisticado que seja, tera a possibilidade de emular com amplitude o cérebro humano muito menos os sentimentos, para justificar, Searle bolou um experimento mental que ficou conhecido como Sala Chinesa.

AUTÔMATOS – MODELOS INTELIGENTES FORA DO TEMPO E DO ESPAÇO

HTTPS://IMAGES.APP.GOO.GL/N5QJGURZQHNUK2VQA

Essa questão vai lá atrás nos anos 1930's quando lógicos matemáticos primeiro começaram a explorar o significado de computação. Avanços tecnológicos desde aquele tempo tem aumentado enormemente nossa capacidade de computar e tem trazido essa questão do domínio da teoria para o mundo do interesse prático. Em cada uma das três áreas autômatos, computabilidade, e complexidade essa questão é interpretada diferentemente, e as respontas variam conforme a interpretação[13].

TEORIA DA COMPLEXIDADE

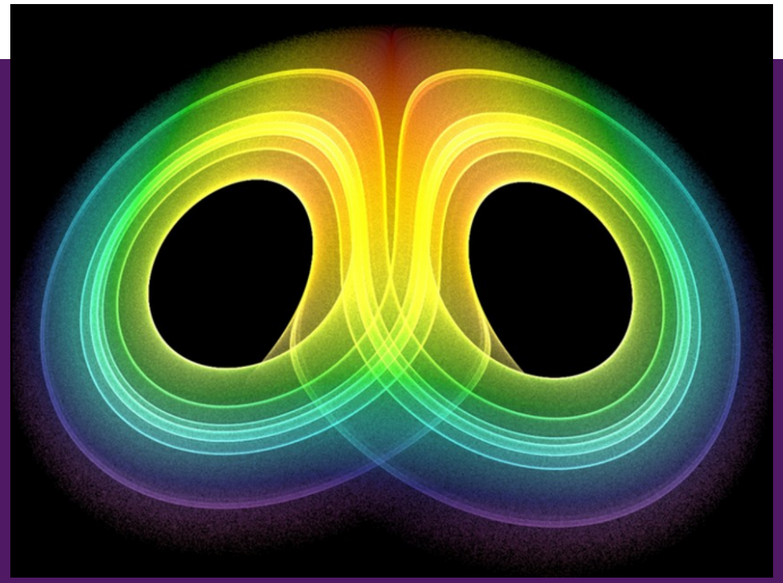

HTTPS://IMAGES.APP.GOO.GL/ZI1YQJ8UWZI3ZJAA7

Problemas computacionais vêm em diferentes variedades: alguns são fáceis e alguns difíceis. Por exemplo, o problema da ordenação é um fácil. Podemos ordenar um milhão de números rapinadamente. Compare isso a um problema de escalonamento ou um problema não linear como reconhecimento de imagem ou padrões[13].

TEORIA DOS AUTÔMATOS

HTTPS://IMAGES.APP.GOO.GL/X7HQXFMUQ9EGPU2C6

Teoria dos autômatos lida com as definições e propriedades de modelos de computação. Esses modelos desempenham um papel em diversas áreas aplicadas da ciência da computação. Um modelo, chamado autômato, é usado para processamento de texto, compiladores, e projeto de hardware. Um outro modelo, chamado gramática livre do contexto, é usado em linguagens de programação e inteligência artificial[13].

AUTÔMATO FINITO DETERMINÍSTICO

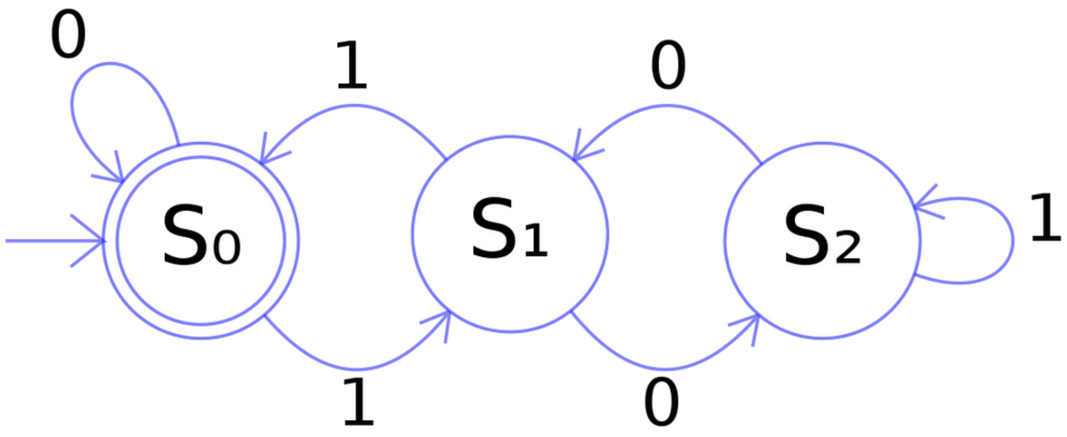

HTTPS://IMAGES.APP.GOO.GL/Z1UWUEVIUXTPJSNX8

Na Teoria dos autômatos, um sub-tópico da Ciência da computação teórica, um autômato finito determinístico — também chamado máquina de estados finita determinística (AFD) — é uma Máquina de estados finita que aceita ou rejeita cadeias de símbolos gerando um único ramo de computação para cada cadeia de entrada[3].

MÁQUINA DE ESTADOS FINITOS NÃO DETERMINÍSTICA

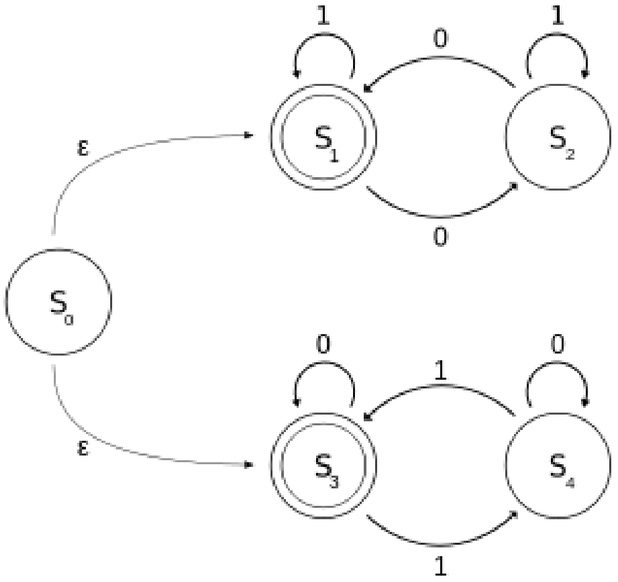

HTTPS://IMAGES.APP.GOO.GL/MDVVZVVFDT5IIZ5W6

Na teoria da computação, uma máquina de estados finita não-determinística ou um autômato finito não-determinístico(AFND) é uma máquina de estados finita onde para cada par de estado e símbolo de entrada pode haver vários próximos estados possíveis[11].

A TEORIA DOS GRAFOS

HTTPS://IMAGES.APP.GOO.GL/MDVVZVVFDT5IIZ5W6

A teoria dos grafos é um ramo da matemática que estuda as relações entre os objetos de um determinado conjunto.

Neurônio Biológico

FONTE:HTTPS://SITES.GOOGLE.COM/SITE/ANATOMIASISTEMANERVOSOCENTRAL/_/RSRC/1401651763408/HOME/NEURONIO/EWQEQWR.JPG

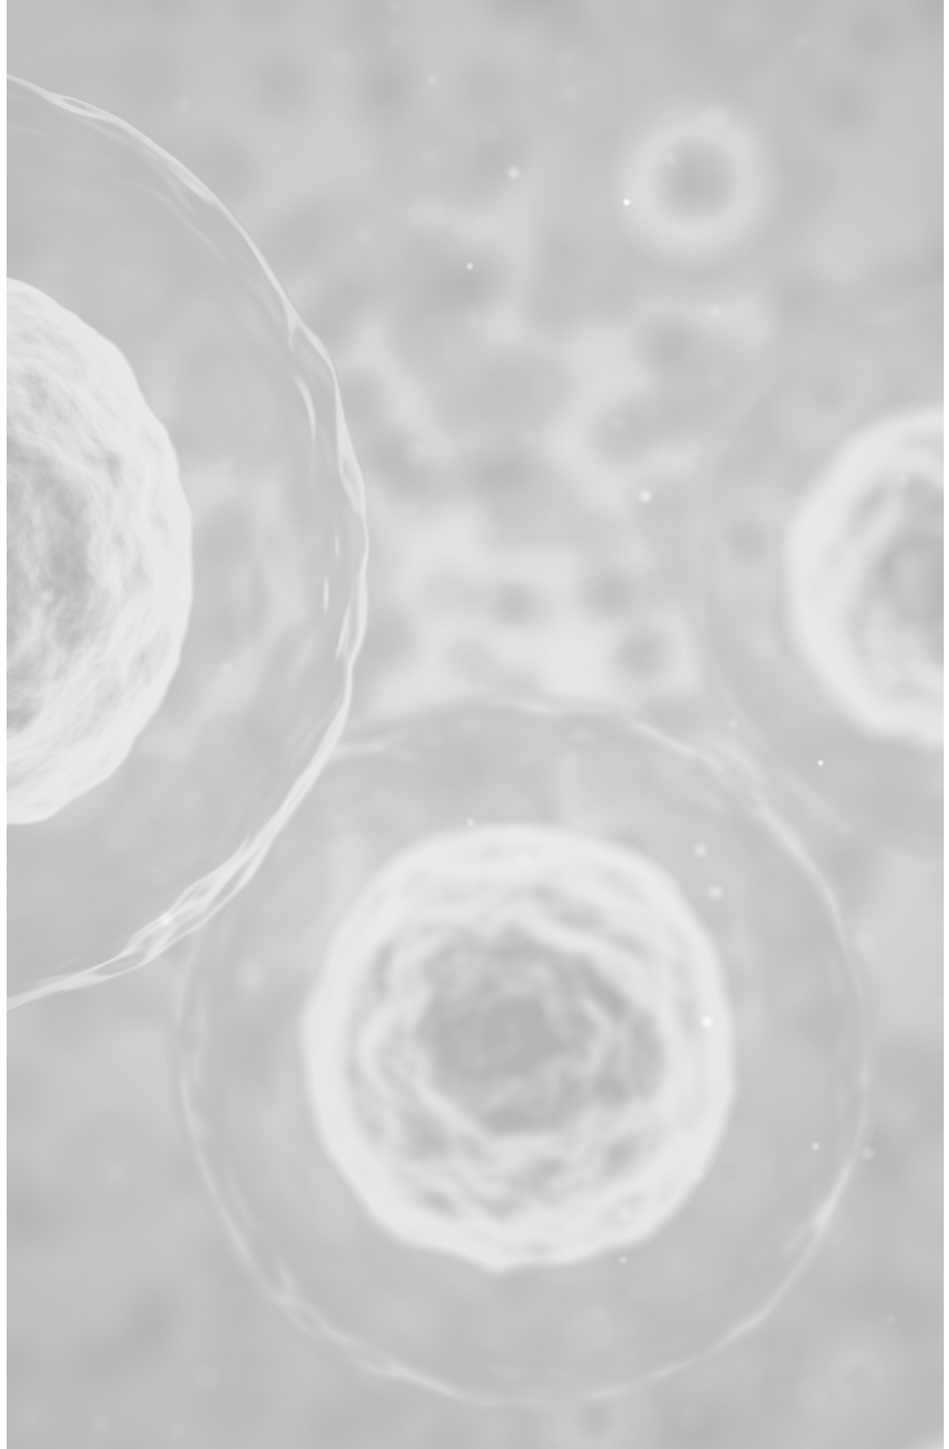

OS NEURÔNIOS INDIVIDUAIS PODEM SER ESTIMULADOS ELETRICAMENTE, QUIMICAMENTE OU MESMO OPTICAMENTE (HAN E BOYDEN, 2007), PERMITINDO QUE OS RELACIONAMENTOS NEURONAIS DE ENTRADA-SAÍDA SEJAM MAPEADOS.

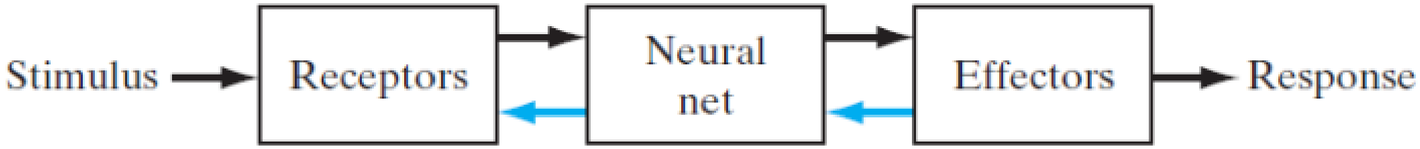

FONTE: HAYKIN, S. NEURAL NETWORKS AND LEARNING MACHINES.

Potencial de Ação

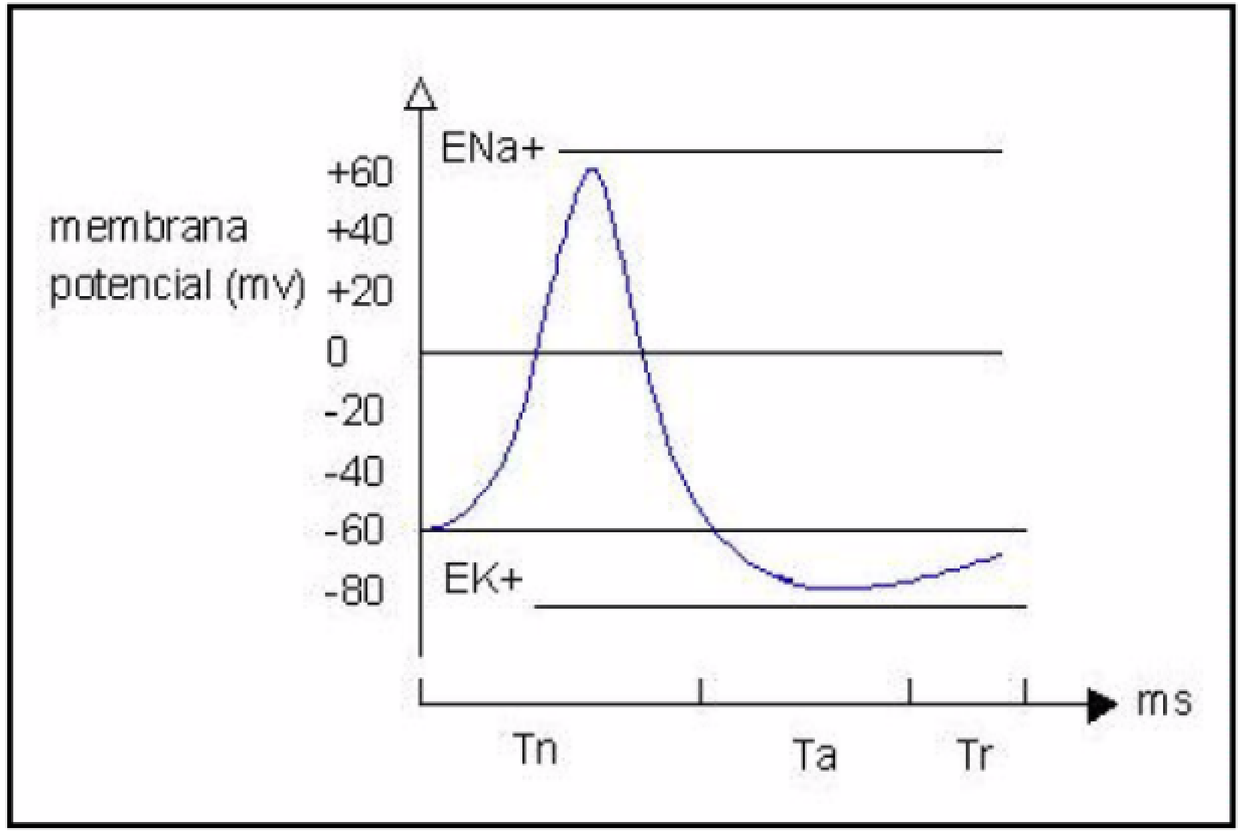

Integração Espacial/Temporal dos Estímulos

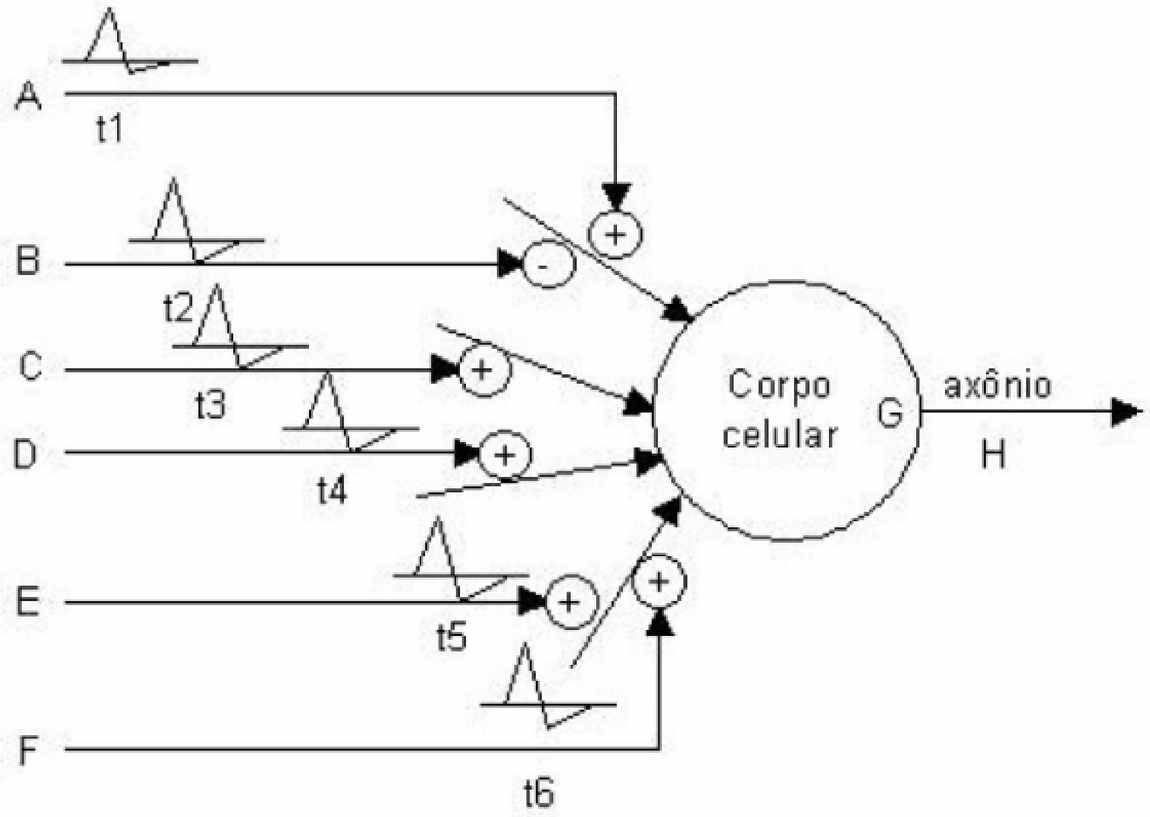

Integração Espacial/Temporal dos Estímulos

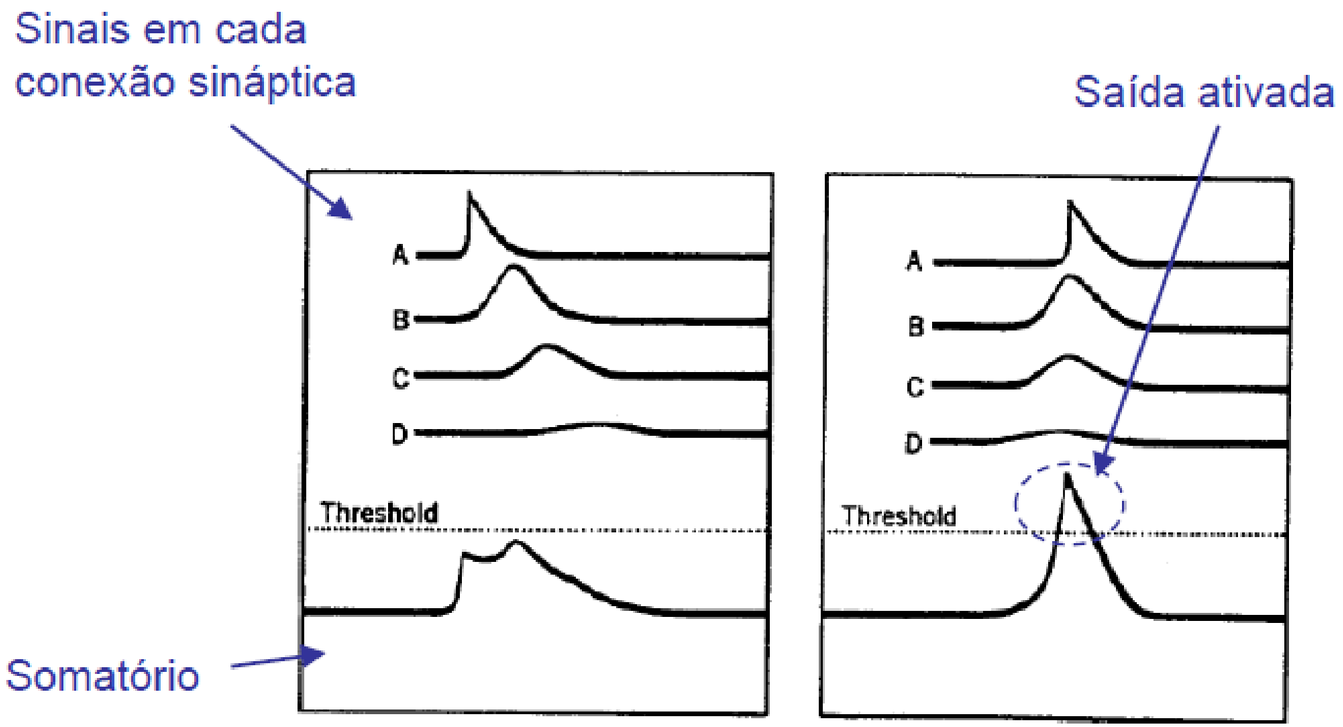

NEURÔNIO ARTIFICIAL

Evolução Histórica:

1943 – McCulloch e Pitts
1948 – Wiener
1949 – Hebb
1952 – Ashby
1954 – Minsky
1954 – Gabor
1955 – Von Neumann
1956 – Taylor
1958 – Rosenblatt
1969 – Minsky e Papert
Década de **70** – “Dark Age” (**1974** – Werbos)
1982 – Hopfield
1986 – Rumelhart, Hinton e Williams
1995 – Vapnik e co-autores
2006 – Hinton e Ruslan Salakhutdinov
2015/2016 – DeepFace/AlphaGo
2017 – adoção em massa do Deep Learning

MODELO DE UM NEURÔNIO ARTIFICIAL PROPOSTO POR MCCULLOCH E PITTS

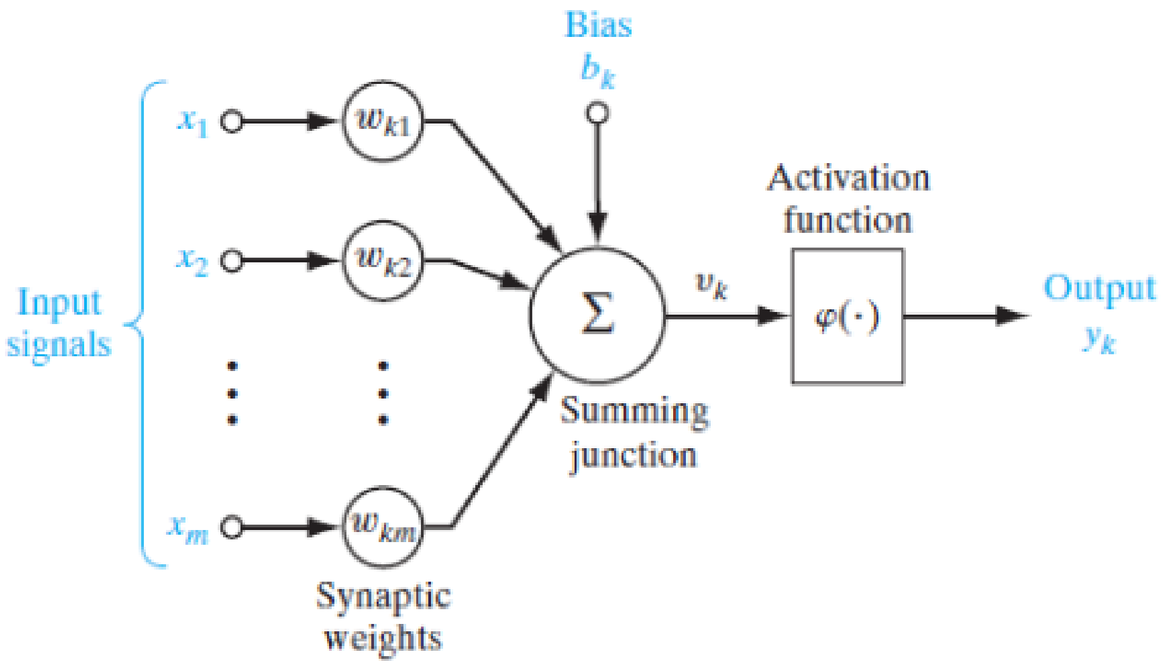

$$v_k = \sum_{j=1}^{m} w_{kj} x_j + b_k$$

$$y_k = \varphi(.) = \varphi(v_k) = sign(v_k)$$

FONTE: HAYKIN, S. NEURAL NETWORKS AND LEARNING MACHINES.

Funções de Ativação

- Limiar: $\varphi(v_k) = \begin{cases} 1, & se\ v_k \geq 0 \\ 0, & se\ v_k < 0 \end{cases}$
- Função Linear por partes: $\varphi(v_k) = \begin{cases} 1, & se\ v_k \geq +\frac{1}{2} \\ v_k, & se\ -\frac{1}{2} < v_k < +\frac{1}{2} \\ 0, & se\ v_k \leq -\frac{1}{2} \end{cases}$
- Função Sigmóide: $\varphi(v_k) = \frac{1}{1+\exp(-av_k)}$
- Extras: https://en.wikipedia.org/wiki/Activation_function

Modos de Treinamento:

SUPERVISIONADO

NÃO-SUPERVISIONADO

HTTPS://IMAGES.APP.GOO.GL/DQRHMZFCN8NJBYE27

TIPOS DE APRENDIZAGEM

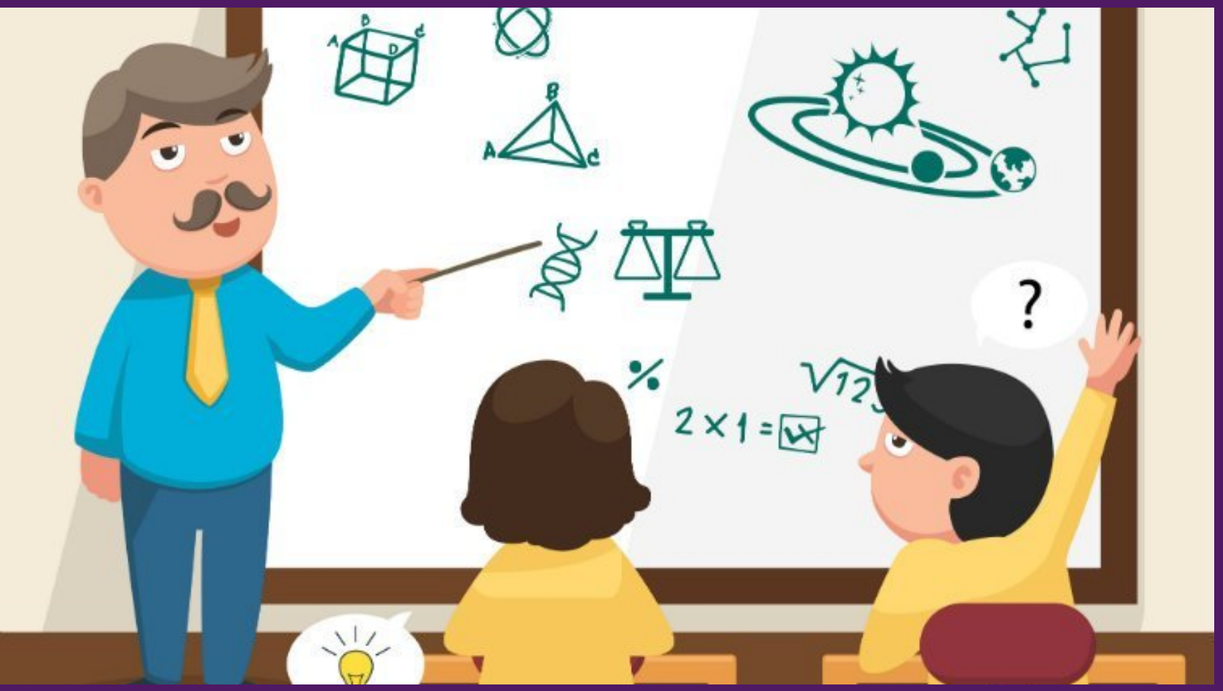

HTTPS://IMAGES.APP.GOO.GL/4CMN4JQXRMNZTD3E7

1. Aprendizagem por **correção e erro**
2. Aprendizagem **baseada em memória**
3. Aprendizagem **Hebbiana**
4. Aprendizagem **competitiva**
5. Aprendizagem de **Boltzmann**

O Perceptron de Rosenblatt

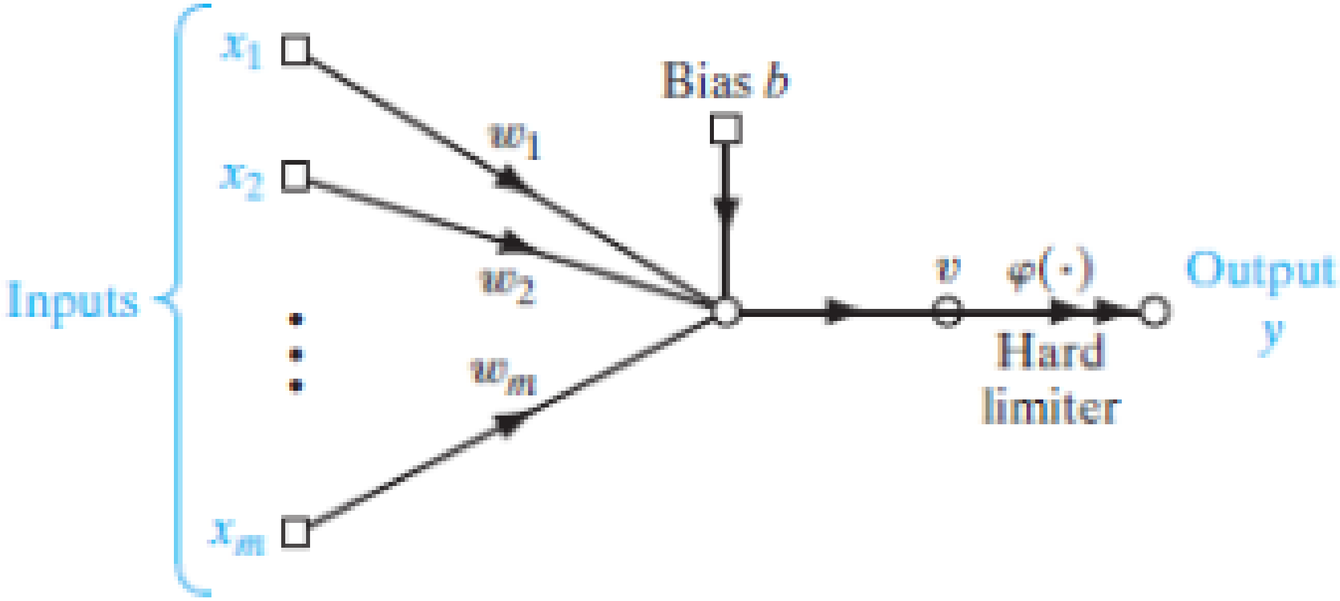

FONTE: HAYKIN, S. NEURAL NETWORKS AND LEARNING MACHINES.

Qual o principal objetivo dele?

Qual o principal objetivo dele?

O que a equação $v_k = \sum_{i=1}^{m} w_i x_i + b = 0$ representa?

Qual o efeito do bias "b" na equação anterior?

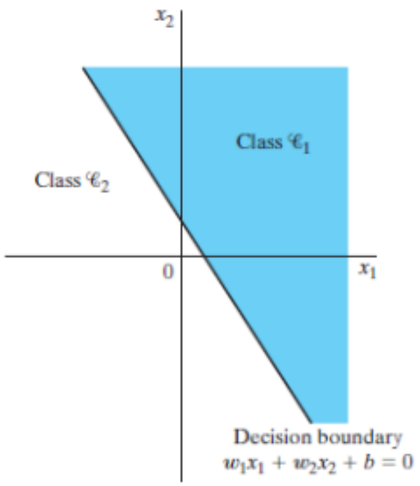

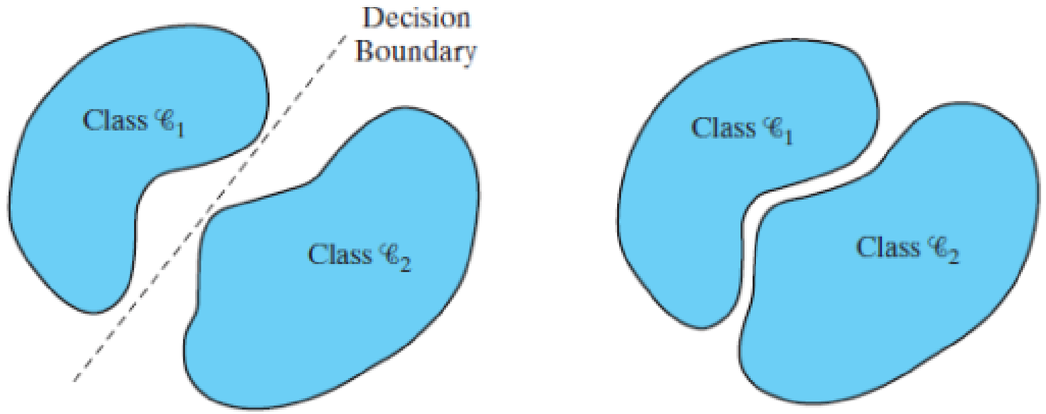

FONTE: HAYKIN, S. NEURAL NETWORKS AND LEARNING MACHINES.

Perceptrons de camada única são bons para resolver problemas de classificação onde as classes são Linearmente Separáveis (LS)

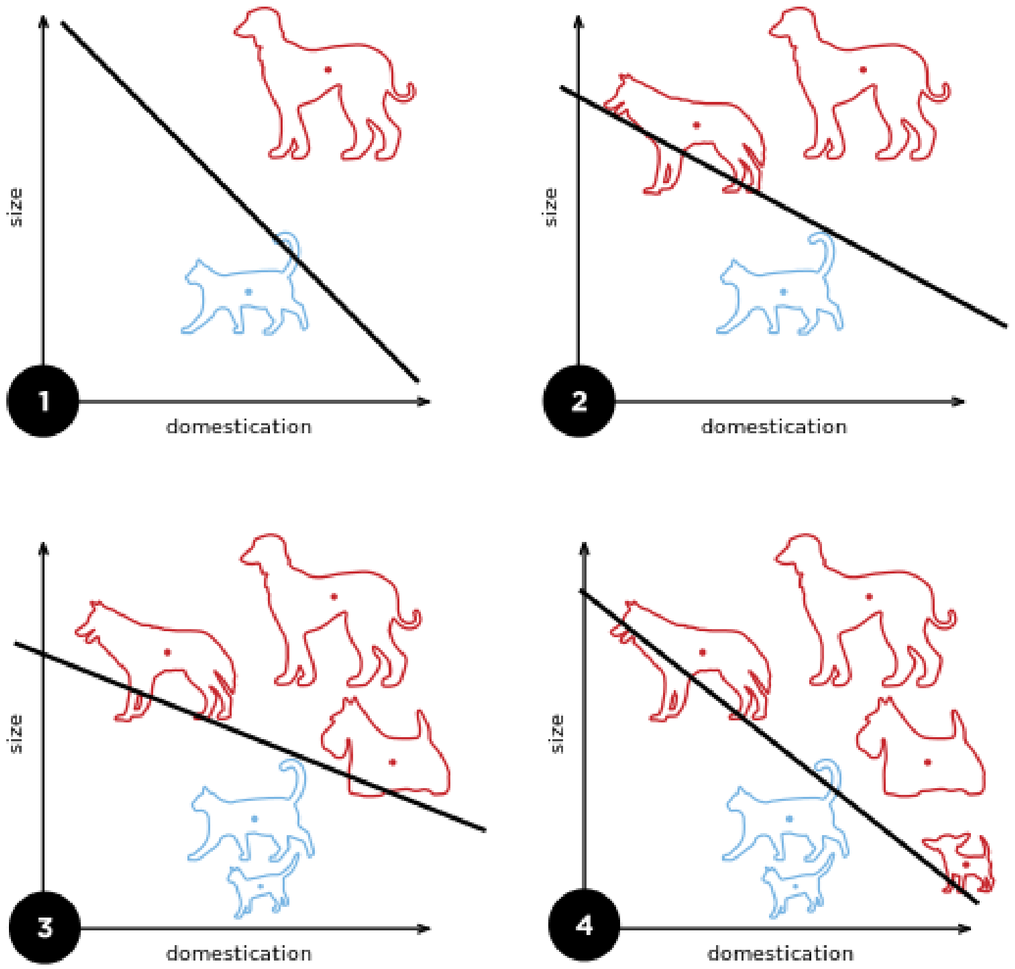

Perceptrons de camada única são bons para resolver problemas de classificação onde as classes são Linearmente Separáveis (LS)

1

Como treinar o perceptron?

2

Como posicionar o hiperplano de forma a solucionar o problema?

Aprendizagem por correção de erro

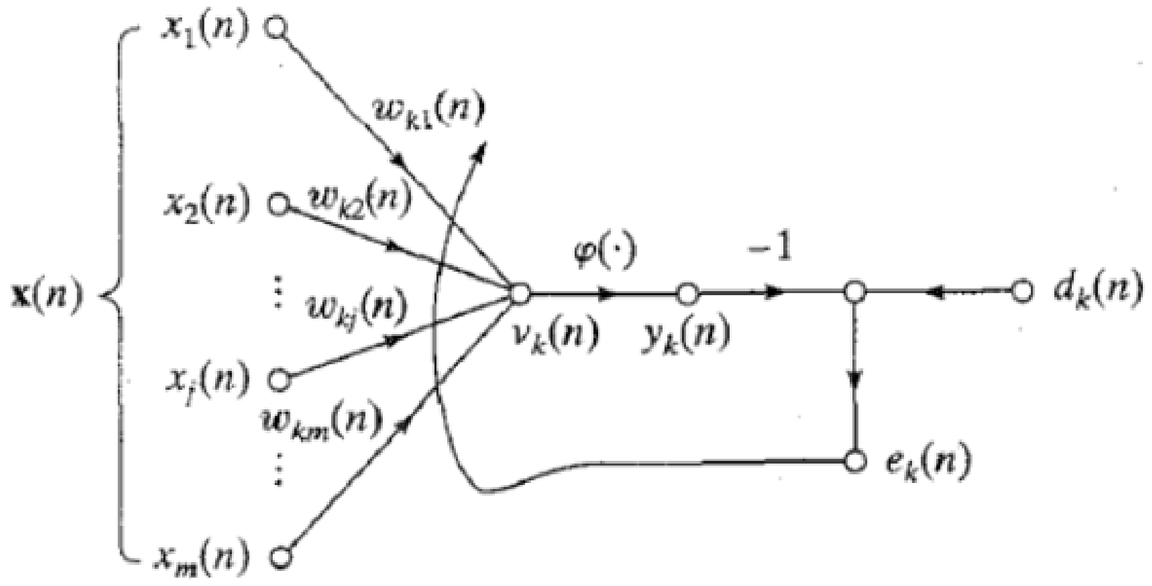

Erro: $e_k(n) = d_k(n) - y_k(n)$

Função de custo ou índice de desempenho: $\varepsilon(n) = \frac{1}{2} e_k^2(n)$

Regra delta ou Widrow-Hoff: $\Delta w_{kj}(n) = \eta e_k(n) x_j(n)$

Peso sináptico atualizado: $w_{kj}(n+1) = w_{kj}(n) + \Delta w_{kj}(n)$

Problema Irrestrito de Otimização:

Minimizar a função de custo $\varepsilon(w)$ em relação ao vetor de pesos w

$$\varepsilon(w^*) \leq \varepsilon(w)$$

onde w^* é o vetor ideal.

Alguns métodos:

1. Método da Descida mais Íngreme;
2. Método de Newton;
3. Método de Gauss-Newton.

Qual o significado do Vetor Gradiente?

O vetor gradiente da função de custo $\varepsilon(w)$ é:

$$\nabla \varepsilon(w) = \left[\frac{\partial \varepsilon}{\partial w_1}, \frac{\partial \varepsilon}{\partial w_2}, \ldots, \frac{\partial \varepsilon}{\partial w_n} \right]^T$$

“Ideia Geral”

Os ajustes nos pesos sinápticos são feitos na direção oposta do vetor gradiente através de um passo ou taxa de aprendizagem η.

O processo de Aprendizagem por correção de erro entra em loop?

O Teorema de convergência do Perceptron

Sejam os subconjuntos de vetores de treinamento T_1 e T_2 linearmente separáveis. Suponha que as entradas apresentadas ao perceptron se originem destes dois subconjuntos. O perceptron converge após n_0 iterações, significando que

$$w(n) = w(n+1) = w(n+2) = \cdots$$

é uma solução para $n_0 \leq n_{max}$.

Exemplo 1: Banco

Considere um banco de dados bancário que contém informações sobre 21 clientes, cada um identificado pelo seu número de conta, que receberam empréstimo do banco em algum momento no passado. Este banco de dados contém os valores dos atributos renda pessoal e dívida (valor do empréstimo concedido) de cada um desses clientes. Além disso, cada cliente foi classificado previamente como bom ou mau pagador, dependendo do seu histórico de pagamento do empréstimo tomado. Por exemplo, se o pagamento de seu empréstimo esteve sempre em dia, ele é considerado um bom pagador. Por outro lado, se o cliente deixou de pagar ou atrasou consideravelmente os seus pagamentos, então ele foi considerado um mau pagador. O problema consiste em determinar um modelo de classificação a partir deste bando de dados, que preveja se um candidato a empréstimo é potencialmente um bom ou mau pagador, a partir dos seus atributos renda e dívida, para que seja tomada a decisão de conceder ou não um novo empréstimo.

"ALGORITMO PARA MELHOR SENÁRIO DE EMPRÉSTIMO"

Exemplo 1: Banco

N_Conta	Renda	Divida	Classe
101	2800	550	bom
102	1300	500	mau
103	1400	80	bom
104	500	200	mau
105	1100	270	mau
106	1800	450	bom
107	2400	650	bom
108	1950	600	bom
109	450	70	mau
110	2750	730	bom
111	850	90	mau
112	1300	200	mau
113	2100	750	bom
114	900	300	mau
115	2700	250	bom
116	1600	500	mau
117	1900	150	bom
118	2500	800	bom
119	1600	700	mau
120	2300	500	bom
121	2100	250	bom

Exemplo 2: Tabelas lógicas

TABELA VERDADE - AND		
A	**B**	**A.B**
0	0	0
0	1	0
1	0	0
1	1	1

OR		
A	B	C
0	0	0
0	1	1
1	0	1
1	1	1

A	B	A **XOR** B
0	0	0
0	1	1
1	0	1
1	1	0

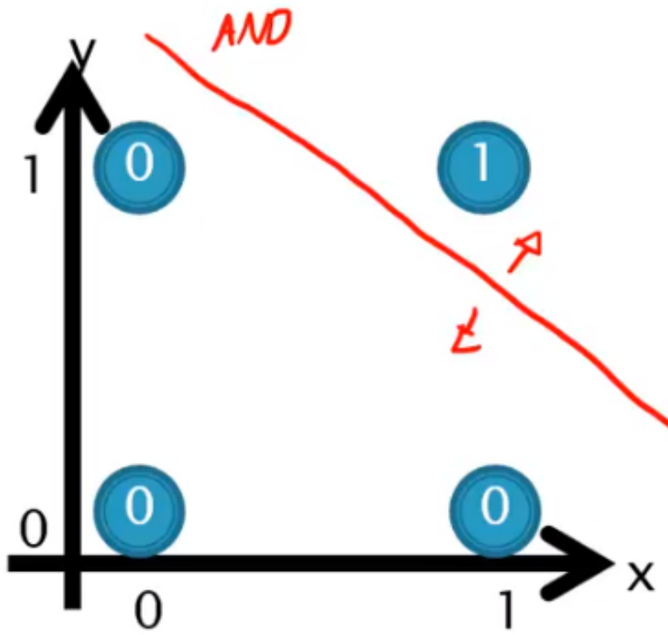

LINEARMENTE SEPARÁVEIS

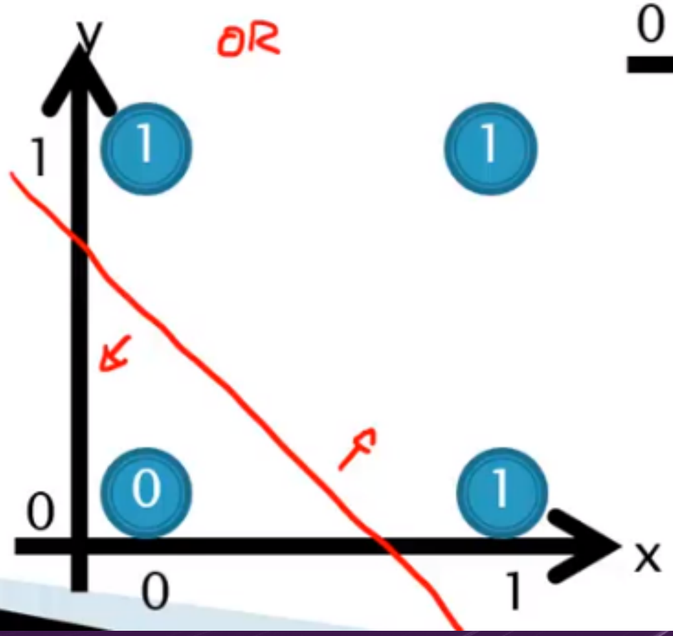

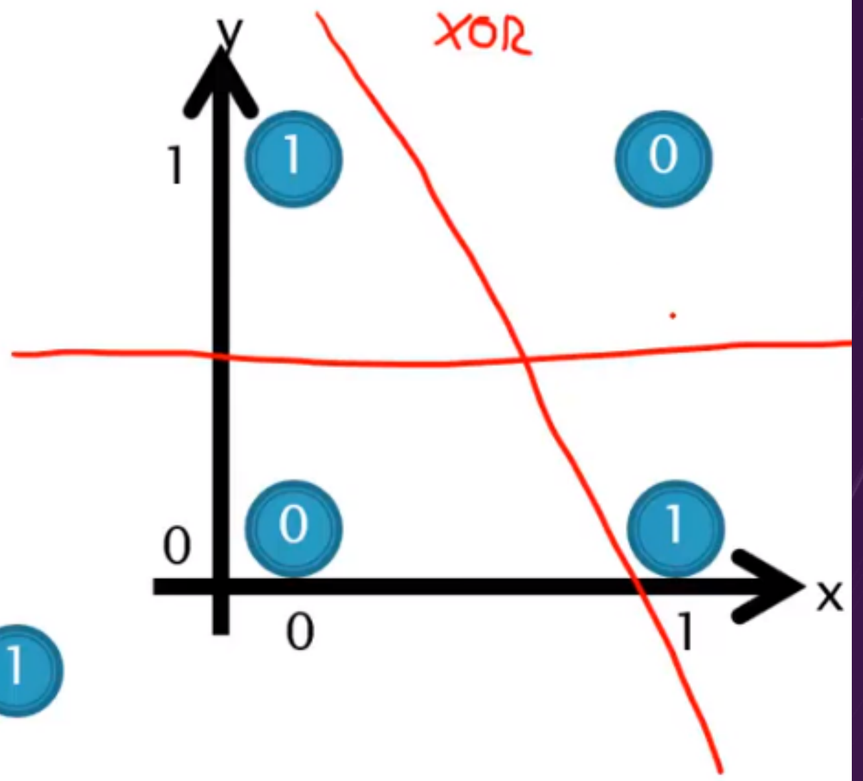

A mostly complete chart of

Neural Networks

©2016 Fjodor van Veen - asimovinstitute.org

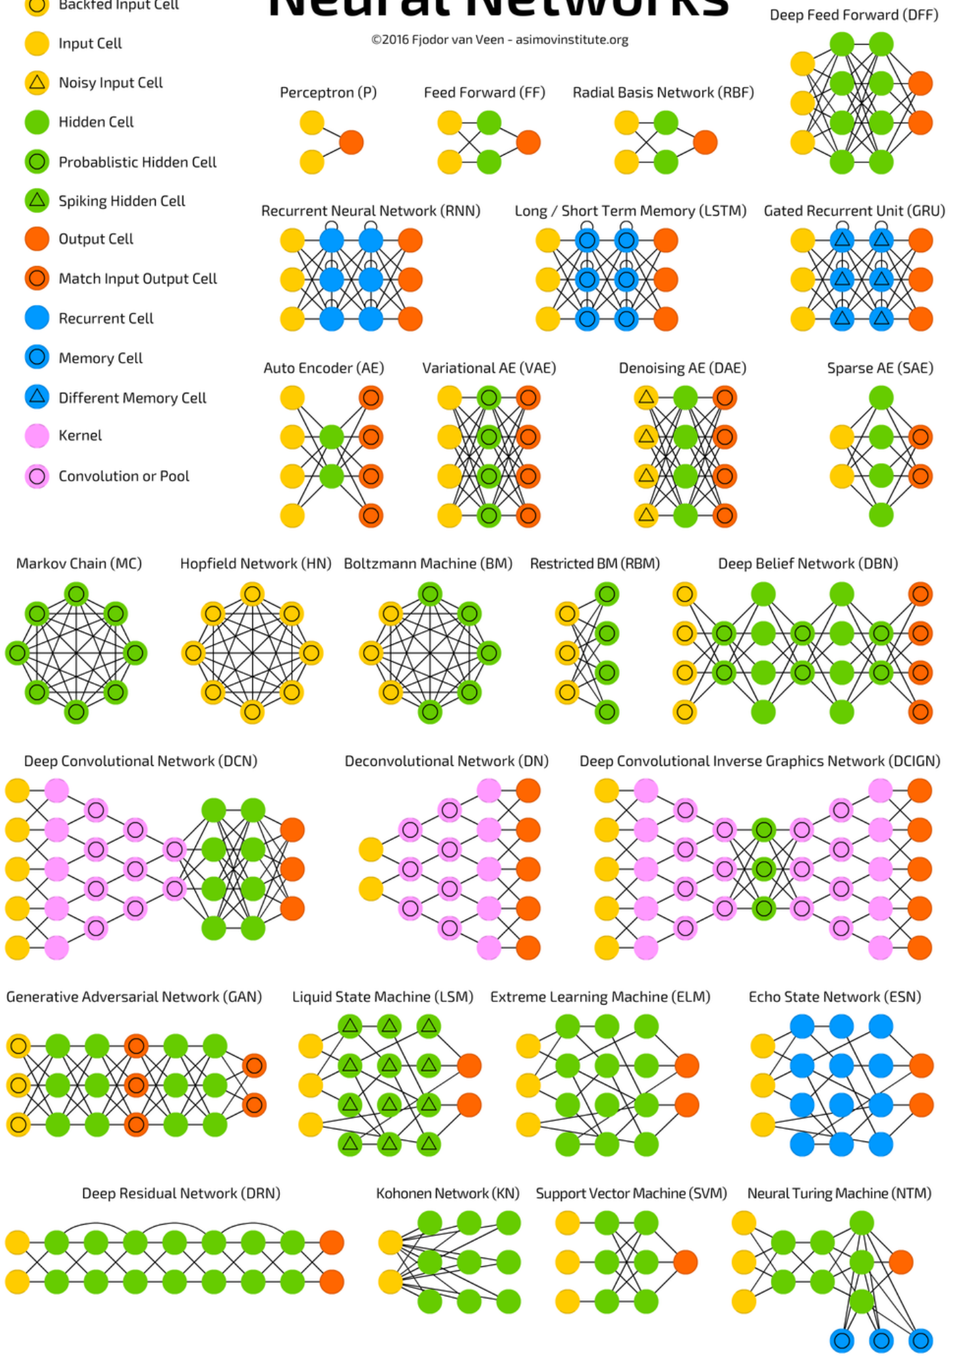

MACHINE LEARNING E DEEP LEARNING

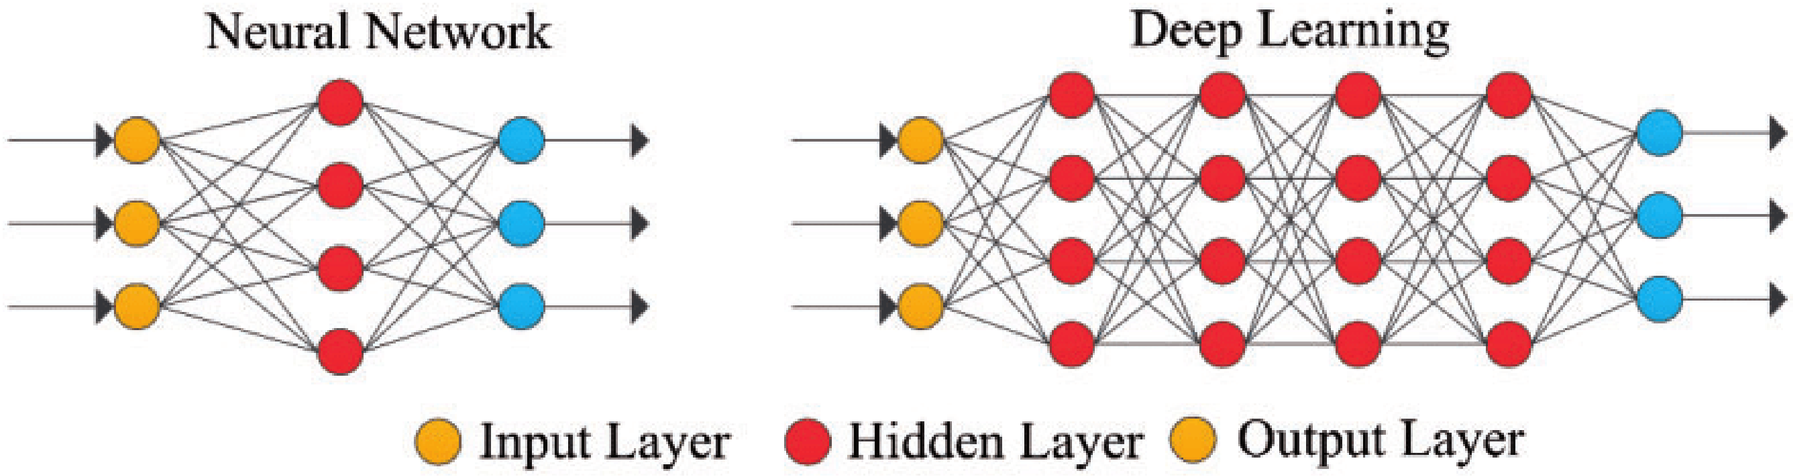

VISÃO COMPUTACIONAL

Reflexão Final!

Qual o papel da Matemática no desenvolvimento das RNA’s?

REFERÊNCIAS BIBLIOGRÁFICAS

[1] AMARAL, F. Introdução a ciência de dados: mineração de dados e Big Data. Rio de Janeiro: Alta Books, 2016

[2] A Sala Chinesa de John Searle. Disponível em https://www20.opovo.com.br/app/colunas/aquitemciencia/2015/07/04/noticiaaquitemciencia,3464099/a-sala-chinesa-de-john-searle.shtml. Acesso em: 19 jun. 2019

[3] Autômato finito determinístico. Disponível em https://pt.wikipedia.org/wiki/Autômato_finito_determinístico. Acesso em: 23 jun. 2019

[4] Dado, Informação, Conhecimento e Competência. Disponível em <https://www.ime.usp.br/~vwsetzer/dado-info.html>. Acessado em: 03/06/2019

[5] DIEGO ZILIO. Inteligência artificial e pensamento: redefinindo os parâmetros da questão primordial de turing. Ciências & Cognição, Rio de Janeiro, Vol 14, nº(1), 208-218, março 2009.

[6] EVANGELISTA. A sala chinesa de John Searle. 2015.

[7] GLEICK, J. A informação: Uma história, uma teoria, uma enxurrada. 1. ed. São Paulo: Companhia das Letras, 2013

[8] HAYKIN, S. Neural networks and learning machines. 3rd ed. Hamilton: Pearson, 2008

[9] HAYKIN, S. Redes neurais: princípios e prática. 2. ed. Porto Alegre: Bookman, 2001

[10] KOVÁCS, Z. L. Redes neurais artificiais: fundamentos e aplicações: um texto básico. 4. ed. São Paulo: Livraria da Física, 2006

[11] Máquina de estados finitos não determinística. Disponível em https://pt.wikipedia.org/wiki/M%C3%A1quina_de_estados_finitos_n%C3%A3o_determin%C3%ADstica. Acesso em: 23 jun. 2019.

[12] RIOUL, O. Teoria da informação e da codificação. São Paulo: Editora da Unicamp, 2018

[13] SIPSER, Michael. Uma Introdução à Teoria da Computação (Versão Parcial: 11 de fevereiro de 2005).

[14] STRATHERN, P. Turing e o computador em 90 minutos. Rio de Janeiro: Editora Zahar, 2000.

OBRIGADO!